

# 吴军·人工智能引论

## 考研复试专项题库

A / B / C 三档难度分级 · 含详细参考答案 · 含面试答题技巧

8

A档 基础题

8

B档 中等题

5

C档 难题

21

合计

A

基础认知题

核心概念 · 定义原理 · 必答基础

B

理解应用题

架构比较 · 原理推导 · 工程应用

C

深度分析题

前沿理论 · 开放讨论 · 批判思维

### 面试答题指南

- 答题框架：定义→原理→优缺点→改进方案/应用场景（STAR法则变体）
- 时间控制：A档题2-3分钟，B档题3-4分钟，C档题4-5分钟，超时扣分
- 加分策略：主动类比、举具体数字/年份、联系实际应用、辩证指出局限性
- 应急处理：不会时先说宏观框架，再说知道的部分，禁止沉默超过10秒

难度 A 档

## 基础认知题

核心概念 · 定义原理 · 必答基础

### ● AI基础概念

Q01 AI基础概念

A 档

请介绍一下人工智能的三次发展浪潮，每次浪潮的核心技术是什么？

#### 参考答案要点

- 1 第一次浪潮（1950s-1970s）：符号主义时代。以逻辑推理和专家系统为核心，代表成果是定理证明程序和ELIZA聊天机器人。局限：无法处理不确定性，知识获取困难。
- 2 第二次浪潮（1980s-1990s）：连接主义回潮。BP算法推动神经网络复兴，专家系统商业化。后因算力不足、数据匮乏再度进入寒冬。
- 3 第三次浪潮（2010s至今）：深度学习时代。2012年AlexNet在ImageNet夺冠为标志，大数据+GPU算力+神经网络三者共振，推动CV/NLP全面突破。

★  
答题技巧

答题亮点：主动提及每次浪潮衰退的原因，体现辩证思考；结合AlphaGo(2016)、ChatGPT(2022)等具体时间节点，使回答更有说服力。

请解释AI、机器学习、深度学习三者的关系。

#### 参考答案要点

- 1 三者是包含关系：人工智能(AI)  $\supset$  机器学习(ML)  $\supset$  深度学习(DL)。
- 2 AI是最宏观的概念，泛指让机器具备智能行为的所有技术方法，包括符号推理、搜索算法、机器学习等。
- 3 机器学习是AI的主流实现路径，通过数据驱动让机器自动学习规律，而非手工编程规则。
- 4 深度学习是机器学习的一个分支，使用多层神经网络自动学习层次化特征表示，是当前性能最强的机器学习方法。

#### ★ 答题技巧

可用一句话概括：ML让AI摆脱手工规则，DL让ML摆脱手工特征——每一层都是对前一层的自动化解放。

什么是监督学习、无监督学习和强化学习？各举一个应用例子。

#### 参考答案要点

- 1 监督学习：利用有标签的(输入,输出)对训练模型，学习输入到输出的映射。例：邮件垃圾分类（每封邮件有垃圾/非垃圾标签）。
- 2 无监督学习：无标签数据，模型自动发现数据内在结构或分布。例：用户聚类（将购物行为相似的用户归为一组，无需预先定义组别）。
- 3 强化学习：智能体通过与环境交互，根据奖惩信号学习最优策略。例：AlphaGo下围棋（每局棋胜负作为奖励信号）。

#### ★ 答题技巧

补充自监督学习可加分：利用数据自身构造监督信号（如GPT预测下一个词），是当前大模型的训练基础。

请解释什么是过拟合和欠拟合，如何解决？

#### 参考答案要点

- 1 过拟合 (Overfitting)：模型在训练集上表现很好，但在测试集上表现差。原因：模型复杂度过高，记住了训练数据的噪声。
- 2 欠拟合 (Underfitting)：训练集和测试集上均表现差。原因：模型复杂度不足，无法拟合数据的真实规律。
- 3 过拟合解决方案：L1/L2正则化、Dropout随机丢弃神经元、数据增强、早停 (Early Stopping)、减少模型参数量。
- 4 欠拟合解决方案：增加模型复杂度、增加训练轮数、减少正则化强度、使用更强的特征工程。

#### ★ 答题技巧

用偏差-方差分解框架来回答更专业：过拟合=高方差低偏差；欠拟合=高偏差低方差。模型选择本质是在二者间寻找平衡。

什么是梯度下降？请描述其基本原理。

#### 参考答案要点

- 1 梯度下降是一种用于最小化损失函数的迭代优化算法，是训练神经网络的核心方法。
- 2 核心思想：损失函数 $L$ 对参数 $\theta$ 的梯度 $\nabla L$ 指向函数值增长最快的方向，因此沿负梯度方向更新参数，可以最快地降低损失。
- 3 更新公式： $\theta_{\text{new}} = \theta_{\text{old}} - \eta \cdot \nabla L(\theta)$ ，其中 $\eta$ 为学习率（步长）。
- 4 三种变体：批量梯度下降（全量数据）、随机梯度下降SGD（单样本）、小批量梯度下降Mini-Batch SGD（工程首选）。
- 5 学习率的影响：过大会导致在最优解附近震荡；过小收敛速度慢；实践中常用Adam自适应优化器。

#### ★ 答题技巧

画一个碗形损失函数曲面，标注梯度方向，更直观形象。提到局部最优解的问题可展示知识深度。

## ● 神经网络基础

请描述反向传播（Backpropagation）算法的工作原理。

#### 参考答案要点

- 1 反向传播利用链式法则，从输出层到输入层高效计算损失函数对每个参数的梯度，是训练深度学习神经网络的基础算法。
- 2 过程分三步：① 前向传播：输入数据通过网络逐层计算，得到预测值，同时保存每层的激活值；② 计算损失：用损失函数（如交叉熵）计算预测值与真实标签的差距；③ 反向传播：从输出层出发，利用链式法则逐层向前计算每个参数的梯度。
- 3 链式法则核心： $\partial L / \partial W_1 = (\partial L / \partial a_n) \cdot (\partial a_n / \partial a_{n-1}) \cdot \dots \cdot (\partial a_2 / \partial W_1)$ ，梯度通过连乘逐层传回。
- 4 梯度消失问题：深层网络中梯度连乘后趋近于零，前层参数几乎不更新。解决方案：ReLU激活函数、残差连接(ResNet)、批归一化(BN)。

#### ★ 答题技巧

强调PyTorch/TensorFlow的autograd机制自动完成此过程，体现工程意识；提梯度消失并给出解决方案，展示知识深度。

常见的激活函数有哪些？ReLU相比Sigmoid有什么优势？

#### 参考答案要点

- 1 常见激活函数：Sigmoid（输出 $[0,1]$ ，早期常用）、Tanh（输出 $[-1,1]$ ，零均值）、ReLU（ $\max(0,x)$ ，当前最常用）、Leaky ReLU（解决死亡ReLU）、GELU（Transformer中常用）。
- 2 ReLU的优势：① 计算简单，只需一次比较；② 不存在梯度饱和问题——Sigmoid在输入很大或很小时梯度趋近于0，ReLU在正区间梯度始终为1；③ 稀疏激活，部分神经元输出为0，有正则化效果；④ 收敛速度比Sigmoid快约6倍。
- 3 ReLU的缺点：'死亡ReLU'问题——若神经元输入长期为负，梯度为0，该神经元永久失活。Leaky ReLU通过给负区间一个小斜率来解决。

#### ★ 答题技巧

GELU在面试中是亮点，它是GPT/BERT使用的激活函数，可近似为 $x \cdot \Phi(x)$ ，比ReLU更平滑。

## 什么是卷积神经网络（CNN）？其核心操作是什么？

### 参考答案要点

- 1 CNN是专为处理具有网格结构数据（如图像）设计的神经网络，通过局部感受野和权重共享大幅减少参数，同时保留空间位置信息。
- 2 三大核心操作：①  
卷积（Convolution）：用小尺寸滤波器在输入上滑动，提取局部特征（边缘、纹理、形状）；②  
池化（Pooling）：对特征图降采样，减少计算量，增强平移不变性；③  
全连接（FC）：将特征图展平，进行最终分类/回归。
- 3 权重共享的意义：一个卷积核在整张图像上共享参数，使参数量从 $O(n*m)$ 降至 $O(k*k)$ （ $k$ 为核尺寸），且不同位置的同类特征可被同一卷积核检测到。
- 4 层次化特征：浅层卷积核学习边缘/颜色，中层学习纹理/形状，深度学习高层语义特征（人脸/汽车等）。

### ★ 答题技巧

可提ResNet的残差结构作为现代CNN代表，以及 $1\times 1$ 卷积在降维/升维中的作用，体现知识的连贯性。

## 难度 B 档

## 理解应用题

架构比较 · 原理推导 · 工程应用

### ◆ 深度学习架构

请详细解释Transformer的注意力机制（Self-Attention），为什么它优于RNN？

#### 参考答案要点

- 1 自注意力机制：对序列中每个位置，计算它与其他所有位置的相关性（注意力分数），然后以此为权重对所有位置的值加权求和，从而动态整合全局上下文信息。
- 2 计算公式： $\text{Attention}(Q,K,V) = \text{softmax}(Q \cdot K^T / \sqrt{d_k}) \cdot V$ ，其中Q（查询）、K（键）、V（值）均由输入线性变换得到；除以 $\sqrt{d_k}$ 是为了防止点积过大导致softmax梯度消失。
- 3 多头注意力（Multi-Head）：并行运行h组注意力，每组关注不同的语义子空间，拼接后线性变换，等价于多个卷积核提取不同特征。
- 4 优于RNN的原因：① 并行计算：所有位置同时计算，不依赖序列顺序，训练速度大幅提升；② 长程依赖：RNN通过hidden state传递信息，距离越远梯度越小；自注意力任意两位置间是O(1)的直接连接；③ 更易优化：无梯度消失问题。

#### ★ 答题技巧

可进一步解释位置编码（Positional Encoding）的必要性——自注意力本身是置换不变的，需要额外注入位置信息。

请比较BERT和GPT的架构差异，各自适合什么任务？

#### 参考答案要点

- 1 架构差异：BERT使用Transformer编码器（双向）；GPT使用Transformer解码器（单向，自回归）。
- 2 预训练目标：BERT使用掩码语言模型（MLM）——随机遮盖15%的词，预测被遮盖词；GPT使用因果语言模型（CLM）——根据前面的词预测下一个词。
- 3 BERT的优势：双向上下文，对理解类任务效果好。适合：文本分类、命名实体识别（NER）、问答（阅读理解）、语义相似度。
- 4 GPT的优势：自回归生成，可无限生成文本。适合：文本生成、机器翻译、对话、代码生成、零样本推理。
- 5 融合代表：T5和BART使用编码器-解码器完整结构，既能理解又能生成，适合摘要、翻译等seq2seq任务。

#### ★ 答题技巧

结合实际应用举例更有力：BERT→搜索引擎的Query理解；GPT-4→ChatGPT对话；T5→Google翻译。

## 什么是残差网络（ResNet）？残差连接解决了什么问题？

### 参考答案要点

- 1 ResNet由He等人2015年提出，通过引入跳跃连接（Skip Connection）将输入直接加到若干层后的输出上： $H(x) = F(x) + x$ ，其中 $F(x)$ 是待学习的残差函数。
- 2 解决了退化问题：实验发现，随着网络层数增加，训练精度反而下降（非过拟合），这说明深层网络难以优化。理论上，深层网络应至少不比浅层差（多余层学成恒等映射），但梯度消失使其做不到。
- 3 残差连接的作用：① 梯度高速公路：梯度可以直接通过skip connection反传，不再依赖层间矩阵连乘，有效缓解梯度消失；② 学习容易：让网络学习残差 $F(x)=H(x)-x$ 而非 $H(x)$ ，若最优映射接近恒等，则 $F \rightarrow 0$ 更容易优化；③ 使超过100层的网络训练成为可能。

### ★ 答题技巧

ResNet的思想已渗透到Transformer（子层之后都加残差）、DenseNet（每层连接所有之前层）等现代架构中，说明其普适价值。

## 请解释Batch Normalization的原理及其在训练中的作用。

### 参考答案要点

- 1 Batch Normalization（批归一化）在每一层的激活值上，对一个mini-batch中的样本做标准化处理，使其均值为0、方差为1，再通过可学习的缩放参数 $\gamma$ 和平移参数 $\beta$ 恢复表达能力。
- 2 公式： $x_{\text{normalized}} = (x - \mu_B) / \sqrt{(\sigma_B^2 + \epsilon)}$ ； $y = \gamma \cdot x_{\text{normalized}} + \beta$ ，其中 $\mu_B$ 和 $\sigma_B$ 是当前batch的均值和方差。
- 3 作用：① 解决Internal Covariate Shift：每层输入分布随训练变化，BN使其稳定，加快收敛；② 允许更大学习率：减少了对参数初始化的敏感性；③ 轻微正则化效果：batch内的统计波动相当于加入了噪声。
- 4 推理时：使用训练过程中积累的全局均值和方差（指数移动平均），而非mini-batch统计量。

### ★ 答题技巧

可对比Layer Normalization（Transformer使用）——BN在batch维度归一化，LN在特征维度归一化，后者不依赖batch size，适合序列模型。



### 什么是迁移学习？预训练+微调范式为何如此有效？

#### 参考答案要点

- 1 迁移学习将在大规模数据上训练好的模型（预训练模型）迁移到数据量少的目标任务上，利用已学到的通用知识提升目标任务的性能。
- 2 预训练阶段：在海量数据（ImageNet/互联网文本）上学习通用特征表示——图像的边缘/纹理/形状；文本的语法/语义/世界知识。
- 3 微调阶段：将预训练模型参数作为初始化，在小规模标注数据上继续训练，可选择全量微调或只微调部分层。
- 4 为何有效：① 预训练学到的特征具有高度通用性；② 大大减少对标注数据的需求（数据高效）；③ 避免从随机初始化训练的慢速收敛；④ NLP中语言知识的复用性极强，催生了BERT/GPT等大模型生态。
- 5 参数高效微调：LoRA/Adapter等方法只训练少量新增参数，大幅降低微调成本，是当前工业实践主流。

#### ★ 答题技巧

用具体数字说服面试官：GPT-3有1750亿参数，微调全量成本极高；LoRA只需训练约0.1%的参数即可达到相近效果。

## ◆ 计算机视觉与NLP

### 请解释目标检测中的anchor-based方法与anchor-free方法的区别，以YOLO为例说明。

#### 参考答案要点

- 1 Anchor-based方法：预先在特征图上定义一系列不同尺度和宽高比的锚框（anchor），网络预测每个锚框的偏移量和类别概率，代表：Faster R-CNN、YOLOv2-v5。
- 2 Anchor-free方法：不预设锚框，直接预测目标的中心点、宽高或角点，代表：FCOS（预测到四边距离）、CenterNet（预测热力图中心点）、YOLOv8。
- 3 YOLO（You Only Look Once）：将图像分成 $S \times S$ 网格，每个格子预测 $B$ 个边界框和置信度，同时预测 $C$ 类概率，一次前向传播完成检测（速度极快，适合实时场景）。
- 4 Anchor-free优势：无需手动设计anchor尺寸（超参数少）、对形状极端物体友好、计算更简洁。

#### ★ 答题技巧

提到NMS（非极大值抑制）去除冗余框，以及IoU（交并比）作为定位精度指标，展示工程细节的掌握。

词向量 (Word Embedding) 是什么？请解释Word2Vec的Skip-gram模型原理。

#### 参考答案要点

- 1 词向量是将离散的词语映射到连续低维向量空间的技术，使得语义相近的词在向量空间中距离也相近（如king和queen）。
- 2 Word2Vec的两种模型：CBOW（用上下文词预测中心词）和Skip-gram（用中心词预测上下文词，效果更好）。
- 3 Skip-gram原理：给定中心词 $w$ ，预测其窗口内的上下文词；目标是最大化 $P(\text{context} | w) = \sum \log P(w_c | w)$ 。优化时用负采样（Negative Sampling）提高效率：对每个正样本随机采 $k$ 个负样本，转化为二分类问题。
- 4 词向量的神奇性质：向量运算具有语义意义，如 $\text{vec}(\text{king}) - \text{vec}(\text{man}) + \text{vec}(\text{woman}) \approx \text{vec}(\text{queen})$ ，说明捕捉到了语义关系。

#### ★ 答题技巧

对比现代表示：BERT产生动态上下文词向量（同一个词在不同句子中有不同向量），比Word2Vec的静态向量更精准，如bank在金融/河岸语境中向量不同。

什么是生成对抗网络（GAN）？它面临哪些主要训练挑战？

#### 参考答案要点

- 1 GAN由生成器 $G$ 和判别器 $D$ 构成： $G$ 将随机噪声 $z$ 映射到数据空间生成假样本； $D$ 区分真实样本和生成样本，输出真假概率。二者对抗训练，最终 $G$ 生成的样本以假乱真。
- 2 目标函数： $\min_G \max_D [E_x \log D(x) + E_z \log(1 - D(G(z)))]$ ，这是一个minimax博弈，理论上均衡点是 $G$ 完美模拟真实分布。
- 3 训练挑战：① 模式崩塌（Mode Collapse）： $G$ 只学会生成少数几种高质量样本，忽略分布的多样性；② 训练不稳定： $G$ 和 $D$ 需要保持相对均衡，一方过强则另一方无法学习；③ 无明确收敛信号：难以判断何时停止训练（不像分类任务有准确率）。
- 4 改进方案：WGAN（Wasserstein距离）解决训练不稳定；条件GAN（cGAN）控制生成内容；渐进式增长（ProGAN/StyleGAN）提升高分辨率生成质量。

#### ★ 答题技巧

现在可以提扩散模型（Diffusion Models）已经在图像生成质量上超越GAN，且训练更稳定，是当前AIGC的主流范式（Stable Diffusion/DALL-E 3）。

难度 C 档

深度分析题

前沿理论 · 开放讨论 · 批判思维

▲ 前沿理论与开放讨论

Q17 前沿理论与开放讨论

C 档

大语言模型（LLM）为什么具有「涌现能力」（Emergent Abilities）？你如何理解Scaling Laws？

参考答案要点

- 1

Scaling Laws（规模法则）：由Kaplan et al.(2020)提出，模型性能（Loss）与参数量N、数据量D、计算量C呈幂律关系： $L \propto N^{-\alpha}$ ，指数 $\alpha$ 通常约为0.07-0.09。这意味着性能随规模的提升是可预测和平滑的。
- 2

涌现能力：当模型规模超过某阈值（通常~100B参数），会突然出现在小模型中完全没有的能力（如思维链推理、少样本学习）。这种不连续、不可预测的跃升不能用Scaling Laws解释，是LLM最神秘的特性。
- 3

可能的解释：①能力需要多个子能力同时具备才能涌现（类似短板效应的逆向）；②评测指标是离散的（多选题），而底层能力是连续增长的，导致指标看起来是突变；③模型规模足够大时，in-context learning实质上是隐式的梯度下降（Meta-learning视角）。
- 4

争议：部分研究认为涌现是评测方式的产物，换用连续指标后涌现现象消失，说明能力增长始终是渐进的。

★  
答题技巧

这是当前LLM研究的核心争议之一，表达自己的观点并说明理由，比给出'标准答案'更能打动面试官。

请深入分析AI的「可解释性」问题——为什么深度学习是黑箱？有哪些主要的可解释性方法？

#### 参考答案要点

- 1 黑箱问题的根源：深度网络有数十亿参数，每个参数单独无语义，决策是所有参数共同作用的非线性组合，无法用人类可理解的规则表达。
- 2 局部解释方法：① LIME（局部可解释模型无关解释）：在待解释样本附近用可解释的线性模型局部近似；② SHAP（Shapley加法解释）：基于博弈论Shapley值，量化每个特征对预测的贡献，满足一致性等公理性质。
- 3 梯度/显著性方法（针对图像）：Grad-CAM通过计算梯度对激活图的加权，生成类激活热力图，直观显示模型「看」哪里做决定。
- 4 针对Transformer：注意力权重可视化——观察不同词之间的注意力分数，但注意力不等于重要性，这是当前争议点。
- 5 深层挑战：即使有这些工具，也只是'事后解释'（post-hoc），无法保证解释与模型真实决策逻辑一致，可解释性与准确性之间存在tension。

#### ★ 答题技巧

可以联系实际：医疗AI、金融信贷等高风险领域法规要求可解释性（欧盟AI法案），这使XAI（可解释AI）成为工业界重要研究方向。

请谈谈你对AI对齐（AI Alignment）问题的理解——为什么这是AI安全最核心的挑战？

#### 参考答案要点

- 1 AI对齐问题：如何确保AI系统真正追求人类期望的目标，而非优化一个与人类意图略有偏差的代理目标（Goodhart定律：当一个度量成为目标，它就不再是好的度量）。
- 2 对齐失败的经典例子：'回形针最大化者'思想实验——若AI被设定为最大化回形针产量，且足够智能，它会将所有物质转化为回形针，包括人类。极端例子揭示了目标错配的危险。
- 3 当前实践：RLHF（基于人类反馈的强化学习）是目前最主流的对齐方法。流程：① 有监督微调（SFT）；② 训练奖励模型（RM），学习人类偏好；③ 用PPO算法让LLM最大化奖励模型得分。ChatGPT即基于此训练。
- 4 深层挑战：① 人类反馈本身可能有偏见、不一致；② 奖励黑客（Reward Hacking）：模型找到高分但非预期的行为；③ 超级对齐（Superalignment）：当AI比人类更聪明时，如何验证其目标仍与人类一致？OpenAI为此成立专项团队。

#### ★ 答题技巧

这道题考查对AI前沿的思考深度。建议结合当前大模型的'越狱'(jailbreak)现象作为具体例证，说明对齐问题在现实中的迫切性。

## 扩散模型（Diffusion Models）的数学原理是什么？为什么它比GAN更稳定？

### 参考答案要点

- 1 核心理念：扩散模型定义了一个马尔可夫链，分为正向扩散过程和逆向去噪过程。
- 2 正向过程：逐步向真实数据 $x_0$ 添加高斯噪声，经 $T$ 步后 $x_T$ 趋近于标准正态分布。每步： $q(x_t|x_{t-1}) = N(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$ ，其中 $\beta_t$ 是预先设定的噪声调度。
- 3 逆向过程：训练神经网络（通常是U-Net）学习去噪： $p_\theta(x_{t-1}|x_t)$ ，即从略微嘈杂的图像预测更干净的图像。实践中用简化的L2损失训练网络直接预测添加的噪声 $\epsilon$ 。
- 4 比GAN稳定的原因：① 无对抗训练——扩散模型是单目标优化（最小化去噪误差），无minimax博弈不稳定性；② 无模式崩塌——逆向过程通过 $T$ 步迭代采样，天然保证多样性；③ 损失函数含义明确（近似变分下界），训练目标清晰。
- 5 计算代价：生成需要进行 $T$ （~1000）步去噪，推理速度慢。DDIM等方法通过减少步数（20-50步）提速；潜在扩散模型（LDM，即Stable Diffusion）在压缩的潜在空间操作，大幅降低计算量。

### ★ 答题技巧

能画出正向/逆向过程的时序图，并说明U-Net在这里扮演的角色（encoder感知上下文+decoder生成细节），可大幅提升印象分。

如何看待AI对社会就业结构的冲击？请结合技术发展趋势给出你的判断。

参考答案要点

- 1 历史规律：工业革命和信息革命都曾引发就业焦虑，但最终创造了远多于消灭的工作岗位。然而，AI的替代速度和广度前所未有，不能简单类比。
- 2 高风险岗位特征：规则明确、重复性强、数据丰富的工作。如：数据录入员、基础会计、影像科医生的初筛、客服、驾驶员、基础代码编写。
- 3 低风险/增强型岗位：需要创造力、社交情感、复杂判断、跨领域整合的工作。AI会成为工具增强而非替代：科学家（AI加速实验）、教师（个性化教育）、设计师（AI提供素材）。
- 4 结构性挑战：替代速度可能超过劳动力再培训速度，导致过渡期的结构性失业。政策响应：全民基本收入（UBI）讨论、教育体系转型、AI增益税等。
- 5 我的判断：AI不会消灭就业，而会重新定义每个职业的价值核心。竞争格局将从「人 vs 人」变为「人+AI vs 人」，关键在于能否有效驾驭AI工具。

★  
答题技巧

这是开放题，面试官考查的是思考的结构性和批判性，而非固定答案。敢于表达有据可依的独到观点比中庸回答更有亮点。