

吴军·人工智能引论

3天速成学习指南
知识点结构 · 重点解析 · 学习策略

学习计划总览

Day 1 第一天：AI基础 · 数学根基 · 机器…

Day 2 第二天：深度学习 · 计算机视觉 · N…

Day 3 第三天：AI应用 · 伦理 · 前沿方向…

第一天重点	专注AI整体框架 + 数学直觉建立。不必深究每个数学公式，理解「为什么用它」比「怎么算」更重要。
第二天重点	动手很关键：配合PyTorch/TensorFlow的官方教程，跑一跑代码，感受CNN和Transformer的实际效果。
第三天重点	联系实际：思考你所在行业哪些场景可以用AI赋能，AI伦理部分建议多思考多讨论。

第一章 人工智能概述

1.1 什么是人工智能

人工智能（Artificial Intelligence, AI）是让机器模拟、延伸和扩展人类智能的科学与技术。吴军老师将AI定义为：通过算法和数据，使计算机具备感知、推理、学习和行动的能力。

强AI vs 弱AI：强AI追求通用智能；弱AI专注特定任务（当前主流）

AI三要素：算法（Algorithm）+ 数据（Data）+ 算力（Computing Power）

AI与机器学习、深度学习的包含关系：AI $\supset$ 机器学习 $\supset$ 深度学习

核心思想：AI本质上是对人类智能的数学化描述，用概率和统计代替确定性规则。

1.2 人工智能发展简史

AI经历了三次浪潮：1950年代-1970年代的符号主义黄金期；1980年代-1990年代的专家系统热潮；2010年代至今以深度学习为核心的第三次浪潮。

1950年：图灵提出图灵测试——机器是否能像人一样思考

1956年：达特茅斯会议，AI正式作为学科诞生

1986年：反向传播算法（BP）重新点燃神经网络研究

2012年：AlexNet在ImageNet大赛夺冠，深度学习时代开启

2016年：AlphaGo击败围棋世界冠军李世石

2022年：ChatGPT引发大模型时代，生成式AI爆发

规律洞察：每次AI浪潮的核心驱动力都是数据量级的跃升 + 算法突破 + 算力提升的共振。

1.3 AI的主要研究方向

按感知→理解→决策→执行的链条，AI覆盖视觉、语言、推理、控制等核心领域。

计算机视觉（CV）：图像分类、目标检测、图像分割

自然语言处理（NLP）：机器翻译、问答系统、文本生成

语音识别与合成：ASR（自动语音识别）、TTS（文本转语音）

推荐系统：协同过滤、内容推荐、强化学习推荐

机器人与自动驾驶：感知-规划-控制闭环

吴军视角：AI最终要解决的核心问题是'不确定性下的最优决策'。

第二章 数学基础

2.1 线性代数核心

线性代数是AI的骨架，所有数据在计算机中以向量和矩阵形式存储与运算。

向量（Vector）：n维空间中的有向量，代表特征

矩阵（Matrix）：线性变换的数学表示，神经网络的权重矩阵

矩阵乘法：神经网络前向传播的本质运算

特征值与特征向量：PCA降维的数学基础

奇异值分解（SVD）：推荐系统矩阵分解的核心工具

神经网络层运算： $Y = W \cdot X + b$ ，其中W为权重矩阵，X为输入向量，b为偏置

直觉理解：矩阵乘法 = 空间变换；神经网络 = 多次连续的线性+非线性变换。

2.2 概率论与统计

AI处理的是不确定的世界，概率论提供了量化不确定性的语言。

概率分布：离散分布（伯努利、多项式）、连续分布（高斯分布最重要）

条件概率： $P(A|B) = P(A \cap B) / P(B)$ ，贝叶斯推断的基础

贝叶斯定理： $P(\theta|X) \propto P(X|\theta) \cdot P(\theta)$ ，后验 $\propto$ 似然 $\times$ 先验

最大似然估计（MLE）：找到使观测数据出现概率最大的参数

期望与方差：描述随机变量的集中趋势和离散程度

贝叶斯定理： $P(\theta|X) = P(X|\theta) \cdot P(\theta) / P(X)$

重要洞察：机器学习的训练过程 = 在参数空间中寻找使数据'最可能'出现的参数值。

2.3 微积分与优化

优化是AI的核心引擎——神经网络训练本质上是一个多维函数的极值求解问题。

导数与梯度：标量函数的导数是切线斜率，向量函数的梯度是最陡上升方向

链式法则：复合函数求导，反向传播的数学基础

梯度下降：沿梯度反方向更新参数，逐步最小化损失函数

学习率（lr）：步长控制，过大震荡，过小收敛慢

凸优化与非凸优化：深度学习是非凸优化，存在多个局部极值

梯度下降更新规则： $\theta_{\text{new}} = \theta_{\text{old}} - \eta \cdot \nabla L(\theta)$ ， η 为学习率， ∇L 为损失函数梯度

工程经验：实践中用Adam优化器（自适应学习率），比纯SGD收敛更稳定。

第三章 机器学习基础

3.1 机器学习三大范式

根据数据是否有标签，机器学习分为三种主要学习范式，各有其适用场景。

监督学习 (Supervised) : 有标签数据，目标是学习输入→输出的映射；分类、回归
无监督学习 (Unsupervised) : 无标签数据，发现数据内在结构；聚类、降维
强化学习 (Reinforcement) : 通过与环境交互获得奖励信号来学习最优策略
自监督学习 : GPT/BERT的基础，从数据本身构造监督信号

选择策略：有标注数据→监督学习；无标注海量数据→无监督/自监督；序贯决策问题→强化学习。

3.2 经典监督学习算法

理解经典算法有助于建立对机器学习的直觉，这些算法至今在工业界广泛使用。

线性回归：最小化均方误差，有解析解；正则化版本L1(Lasso)/L2(Ridge)
逻辑回归：用Sigmoid函数将线性输出映射到[0,1]概率，二分类利器
决策树：基于信息增益 (ID3/C4.5) 或基尼系数 (CART) 分裂节点
随机森林：多棵决策树投票，Bagging降低方差，特征随机化增强多样性
XGBoost/LightGBM：Boosting集成，串行建树，工业界结构化数据首选
SVM：最大化分类间隔，核技巧将非线性问题转化为线性问题

实用原则：结构化数据→梯度提升树 (XGBoost) ；非结构化数据 (图像/文本) →深度学习。

3.3 模型评估与过拟合

好的模型需要在训练集和测试集上都有良好表现，偏差-方差权衡是核心问题。

训练集/验证集/测试集划分：通常 80/10/10 或 70/15/15
交叉验证 (K-Fold) : 减少数据划分带来的随机性
过拟合 (Overfitting) : 训练好测试差，模型记住了噪声
欠拟合 (Underfitting) : 训练和测试都差，模型复杂度不足
正则化手段：L1/L2正则、Dropout、数据增强、早停 (Early Stopping)
分类评估指标：准确率、精确率、召回率、F1、AUC-ROC

$F1-Score = 2 \cdot (Precision \cdot Recall) / (Precision + Recall)$ ，平衡精确率与召回率

黄金法则：始终在测试集 (未见过的数据) 上评估最终模型，不能用测试集调参。

第四章 深度学习与神经网络

4.1 神经网络基础

人工神经网络受生物神经元启发，通过多层非线性变换学习数据的层次化表示。

神经元模型：加权求和 + 激活函数，模拟生物神经元的激发机制

激活函数作用：引入非线性，使网络可以拟合任意复杂函数

常用激活函数：Sigmoid（输出层分类）、ReLU（隐层首选）、Tanh、GELU

全连接层（FC）：每个神经元与上一层所有神经元连接

通用近似定理：单隐层足够宽的神经网络可近似任意连续函数

神经元输出： $h = \text{ReLU}(W \cdot x + b) = \max(0, W \cdot x + b)$

深度的意义：深层网络可以用指数级更少的参数表达复杂函数，而非简单叠加浅层。

4.2 反向传播算法

反向传播（Backpropagation）是训练神经网络的核心算法，利用链式法则高效计算梯度。

前向传播：从输入层到输出层计算预测值，记录中间激活值

计算损失：预测值与真实标签的差距（交叉熵/MSE）

反向传播：从输出层到输入层，用链式法则逐层计算梯度

梯度消失问题：深层网络中梯度指数衰减，使前层参数几乎不更新

梯度爆炸：梯度指数增大，参数更新不稳定，用梯度裁剪解决

解决方案：残差连接（ResNet）、Batch Normalization、良好的权重初始化

链式法则： $\partial L / \partial W_i = (\partial L / \partial a_n) \cdot (\partial a_n / \partial a_{n-1}) \cdot \dots \cdot (\partial a_{i+1} / \partial W_i)$

工程要点：PyTorch/TensorFlow的autograd自动计算梯度，不需要手动推导BP。

4.3 训练技巧与优化器

深度网络的训练需要大量工程经验，正确的训练策略是取得好结果的关键。

批量梯度下降 (BGD) / 小批量 (Mini-Batch SGD) / 随机梯度下降 (SGD)

Momentum动量：累积历史梯度，加速收敛，减少震荡

AdaGrad/RMSProp：自适应调整每个参数的学习率

Adam优化器：结合Momentum和RMSProp，当前最常用的优化器

学习率调度：余弦退火、阶段式降低 (Step Decay)、Warmup策略

权重初始化：Xavier/He初始化，避免信号在前向传播中消失或爆炸

默认推荐：Adam优化器 + 适当Warmup + 余弦退火，基本适用于大多数任务。

第五章 卷积神经网络与计算机视觉

5.1 卷积神经网络 (CNN)

CNN通过局部感受野、权重共享和池化操作，高效处理具有空间结构的图像数据。

卷积操作：用滤波器在特征图上滑动，提取局部特征 (边缘、纹理、形状)

权重共享：同一个卷积核在整张图像上滑动，大幅减少参数量

特征图 (Feature Map)：卷积核对输入的响应图，反映特定特征的位置

池化 (Pooling)：Max Pooling保留最显著特征，降低分辨率

深层特征层次：浅层=边缘/颜色，中层=纹理/形状，深层=语义/物体

感受野 (Receptive Field)：深层神经元能「看到」的原始输入范围

卷积输出尺寸：
$$\text{out} = (\text{in} + 2 \cdot \text{pad} - \text{kernel}) / \text{stride} + 1$$

关键洞察：深度足够的CNN会自动学习从像素到语义的层次化特征，无需手工设计。

5.2 经典CNN架构演进

了解架构演进史，有助于理解现代网络设计的核心思想。

LeNet（1998）	：第一个实用CNN，用于手写数字识别，奠定CNN基本结构
AlexNet（2012）	：深度学习革命的起点，引入ReLU/Dropout/数据增强
VGG（2014）	：深层小卷积核（3x3），架构简洁，易于理解
GoogLeNet/Inception（2014）	：多尺度并行卷积，Inception模块
ResNet（2015）	：残差连接解决梯度消失，成功训练超过100层网络
EfficientNet/MobileNet	：轻量化设计，适合移动端部署

ResNet是里程碑：残差连接让梯度可以「跳过」中间层直接回传，使训练超深网络成为可能。

5.3 视觉任务全景

计算机视觉的四大核心任务构成了从感知到理解的完整链条。

图像分类	：给整张图打标签（ImageNet：1000类，Top-1准确率是基准）
目标检测	：找到图中所有物体的位置（边界框）和类别；YOLO/Faster RCNN
语义分割	：对每个像素分类；FCN/U-Net/SegNet
实例分割	：区分同类中不同个体；Mask R-CNN
图像生成	：GAN（对抗生成网络） / Diffusion Model（扩散模型）
评估指标	：mAP（均值平均精度）用于检测；mIoU用于分割

YOLO系列在实时检测中是工业标准，Diffusion Model是当前图像生成的SOTA。

第六章 自然语言处理与大语言模型

6.1 文本表示：从词袋到词向量

让计算机理解文字的第一步是将文本转化为有意义的数值表示。

词袋模型 (BoW) : 忽略顺序, 统计词频, 无法表达语义
TF-IDF : 词频×逆文档频率, 突出重要词, 压制常见词
Word2Vec (2013) : 词嵌入, 语义相近的词在向量空间中距离近
GloVe : 基于全局共现矩阵的词向量, 与Word2Vec互补
词向量的神奇性 : king - man + woman ≈ queen (语义运算)
子词分词 (BPE/WordPiece) : 处理未登录词, GPT/BERT使用

革命性意义：词向量把离散符号转化为连续向量空间，让文本可以做「数学运算」。

6.2 Transformer架构

2017年「Attention is All You Need」提出的Transformer架构彻底改变了NLP乃至整个AI领域。

自注意力 (Self-Attention) : 序列中每个位置关注其他所有位置, 动态计算关系
多头注意力 (Multi-Head) : 从多个角度关注信息, 类比CNN的多个卷积核
位置编码 (Positional Encoding) : 弥补自注意力无序性, 注入位置信息
前馈网络 (FFN) : 每个位置独立的两层MLP, 增加非线性表达
编码器-解码器架构 : Encoder理解输入, Decoder生成输出
Layer Normalization + 残差连接 : 稳定训练的关键组件

注意力计算 : $\text{Attention}(Q,K,V) = \text{softmax}(Q \cdot K^T / \sqrt{d_k}) \cdot V$

注意力的本质：查询(Q)和键(K)的相似度决定对值(V)的加权聚合，实现动态信息整合。

6.3 预训练大语言模型（LLM）

「预训练+微调」范式颠覆了NLP，催生了GPT、BERT等一系列里程碑模型。

BERT（2018）：双向编码器，掩码语言模型（MLM）预训练，理解任务SOTA

GPT系列：单向解码器，自回归语言模型，生成能力强大

GPT-3/4（2020-2023）：千亿参数，少样本学习（In-context Learning）涌现

指令微调（Instruction Tuning）：让模型更好地遵循人类指令

RLHF（基于人类反馈的强化学习）：ChatGPT的核心训练方法

提示工程（Prompt Engineering）：精心设计输入提示，引导模型输出

涌现能力（Emergent

Abilities）：当模型规模超过阈值，会突然出现在小模型中没有的能力——这是LLM最神秘的特性。

第七章 AI核心应用领域

7.1 推荐系统

推荐系统是AI商业价值最直接的体现之一，覆盖电商、视频、社交等几乎所有互联网场景。

协同过滤（CF）：基于用户或物品的相似性推荐，用户-物品交互矩阵

矩阵分解（MF）：将稀疏的用户-物品矩阵分解为低秩密集表示

深度推荐模型：Wide&Deep; / DIN / DIEN 等，结合记忆与泛化

召回→排序→重排三阶段架构：工业级推荐系统的标准流程

冷启动问题：新用户/新物品缺乏历史数据，用内容特征或规则兜底

探索-利用权衡（Exploration vs Exploitation）：平衡推新品与推已知喜好

吴军洞见：推荐系统的本质是「信息过滤」——从海量内容中找到此时此刻最适合这个用户的内容。

7.2 自动驾驶

自动驾驶是AI+机器人技术的集大成者，代表AI向物理世界延伸的最高挑战之一。

感知层：摄像头/激光雷达/毫米波雷达融合，目标检测与跟踪

高精地图：厘米级精度的地图，提供先验环境信息

定位：GNSS + IMU + 激光雷达SLAM融合定位

预测层：预测周围车辆、行人的轨迹

规划层：路径规划（A*等）+ 行为决策 + 运动规划

控制层：将规划轨迹转化为油门/刹车/方向盘指令

L2~L5级别：L2是辅助驾驶（人监督）；L4是特定场景全自动；L5是全场景全自动（尚未实现）。

7.3 AI医疗

医疗AI是AI最具社会价值的应用之一，辅助诊断、新药研发、个性化治疗是三大方向。

- 医学影像分析：CT/MRI/病理图像的AI辅助诊断，已超越部分专科医生
- 临床NLP：从电子病历中提取结构化信息，辅助诊断和编码
- AlphaFold2（2020）：DeepMind用AI预测蛋白质三维结构，破解50年难题
- AI新药研发：分子性质预测、虚拟筛选、生成式分子设计
- 挑战：数据隐私（HIPAA/GDPR）、标注成本高、监管审批严格

AlphaFold是AI科学发现的里程碑，证明AI不仅是工具，还能做出真正的科学贡献。

第八章 生成式AI与多模态

8.1 生成对抗网络（GAN）

GAN通过生成器和判别器的对抗博弈，学习真实数据的分布，从而生成以假乱真的内容。

- 生成器（G）：将随机噪声映射到数据空间，生成逼真样本
- 判别器（D）：区分真实样本和生成样本，给出真假概率
- 对抗训练：G试图骗过D，D努力识别G；双方博弈达到纳什均衡
- 模式崩塌（Mode Collapse）：G只生成少数几种样本的常见训练问题
- 条件GAN（cGAN）：通过条件向量控制生成内容的属性
- DCGAN/StyleGAN/BigGAN：图像生成质量逐代提升的经典架构

GAN目标函数： $\min_G \max_D [E_x \log D(x) + E_z \log (1 - D(G(z)))]$

GAN的博弈论本质：零和博弈，理论上收敛点是生成器完美模拟真实分布。

8.2 扩散模型 (Diffusion Models)

扩散模型通过逐步去噪的方式生成高质量内容，已超越GAN成为图像生成的主流范式。

正向过程：逐步向数据添加高斯噪声，直至完全变为随机噪声

反向过程：训练神经网络学习去噪，从噪声逐步还原为真实数据

DDPM (2020)：扩散模型的奠基性工作，图像质量大幅超越GAN

Stable Diffusion：基于潜在扩散模型 (LDM)，在压缩的潜在空间操作

CLIP引导：文本编码器提供语义条件，实现「文本→图像」生成

Sora (2024)：视频扩散模型，将扩散模型延伸到视频生成

扩散模型优势：训练稳定（无对抗博弈）、多样性好、质量高，是当前AIGC的主流基础。

8.3 多模态AI

多模态AI打通了视觉、语言、语音等不同模态之间的语义鸿沟，是迈向通用AI的重要一步。

CLIP (OpenAI)：对比学习对齐图像和文本的语义空间，零样本视觉分类

DALL-E / Midjourney：文本到图像生成，创意工具革命

GPT-4V / Gemini：大型多模态模型，可理解图像+文本的混合输入

语音-文本对齐：Whisper等ASR模型，实现高精度语音转文字

具身智能 (Embodied AI)：多模态感知 + 物理世界交互，机器人的未来方向

统一表示空间是多模态的核心：通过对比学习或生成式预训练，将不同模态映射到同一语义空间。

第九章 AI伦理、安全与未来

9.1 AI伦理问题

随着AI渗透到社会各个层面，其引发的伦理问题已成为技术发展不可避免的重要议题。

- 算法偏见：训练数据的历史偏见被模型放大，导致歧视性决策
- 隐私侵犯：人脸识别、行为追踪对个人隐私的威胁
- 虚假信息：深度伪造（Deepfake）、AI生成的虚假内容泛滥
- 黑箱问题：深度学习模型缺乏可解释性，「可解释AI（XAI）」成为重要研究方向
- 自主武器：AI军事化应用的道德边界
- 就业替代：自动化对劳动力市场的冲击，低技能工作首先受影响

吴军观点：技术中立，但使用有道德责任。AI伦理不是阻碍创新，而是可持续发展的保障。

9.2 AI安全与对齐

AI安全研究确保AI系统按照人类意图行事，避免产生有害或失控的行为。

- 对抗样本（Adversarial Examples）：人眼看不出差异，却能骗过AI的图像扰动
- 模型鲁棒性：分布偏移（Out-of-Distribution）下的性能保证
- AI对齐（Alignment）：确保AI目标与人类价值观一致，防止目标错配
- RLHF（人类反馈强化学习）：OpenAI训练ChatGPT对齐人类偏好的方法
- 红队测试（Red Teaming）：主动攻击自己的AI系统以发现漏洞
- 监管框架：欧盟《AI法案》等，分风险等级监管AI应用

超级对齐是AI领域最重要的长期问题：如何确保比人类聪明的AI仍然服务于人类？

9.3 AI前沿与未来展望

当前AI正处于飞速演进期，理解前沿方向有助于把握技术发展脉络。

通用人工智能（AGI）：多领域通用能力，OpenAI/DeepMind将其列为终极目标

AI Agent：具备规划、记忆、工具使用能力的自主AI代理

Scaling Laws：模型能力随参数/数据/算力的幂律增长规律

神经符号AI（Neurosymbolic AI）：融合深度学习与符号推理，增强推理能力

量子机器学习：量子计算与ML的结合，理论上加速特定类型问题

科学AI（AI for Science）：AlphaFold开创的用AI解决科学问题的新范式

吴军的预判：AI不会像科幻中那样取代人类，而是作为「超级工具」极大扩展人类的能力边界。

第一天重点

专注AI整体框架 + 数学直觉建立。不必深究每个数学公式，理解「为什么用它」比「怎么算」更重要。

第二天重点

动手很关键：配合PyTorch/TensorFlow的官方教程，跑一跑代码，感受CNN和Transformer的实际效果。

第三天重点

联系实际：思考你所在行业哪些场景可以用AI赋能，AI伦理部分建议多思考多讨论。

推荐配套资源

吴恩达 DeepLearning.AI 课程 (Coursera)
Fast.ai 实践课程
Papers with Code (追踪最新SOTA)
Hugging Face文档 (实战大模型)

学习方法论

「费曼学习法」：学完每个章节，尝试用自己的语言向别人解释。能解释清楚才是真正掌握。